

Università degli Studi Roma Tre

Scuola di Economia e Studi Aziendali

Dipartimento di Economia



Corso di Laurea in Economia e Big Data - L-33

ANALISI DEGLI EFFETTI MACROFINANZIARI DELL'ALTERNANZA POLITICA
NEGLI USA CON MODELLI DI DEEP LEARNING

Laureando

GIORGIO MARIA MAIOLI

N. Matr. 590215

Relatore

Chiar.mo Prof. FRANCESCO BENEDETTO

A.A. 2023/2024

Indice

1	Introduzione	4
1.1	Il contesto	4
1.2	Analisi dello stato dell'arte e ricerca della letteratura	5
1.3	Determinazione dell'obiettivo di ricerca	7
1.4	Struttura della tesi	7
2	Fondamenti teorici e domain knowledge	9
2.1	Descrizione dei modelli utilizzati	9
2.1.1	Temporal Fusion Transformer	9
2.1.2	Long Short Term Memory	10
2.2	Scelta delle features	11
2.2.1	Introduzione	11
2.2.2	Categorie di variabili e motivazioni teoriche	11
2.2.3	Distinzione tra Known e Unknown Variables	13
3	Metodologia sperimentale	15
3.1	Preprocessing e pulizia dei dati	15
3.1.1	Caricamento e reindicizzazione del dataset	15
3.1.2	Interpolazione dei valori mancanti	15
3.1.3	Unificazione del fuso orario	15
3.1.4	Merge con informazioni politiche e macroeconomiche	16
3.2	Feature Engineering	16
3.2.1	Creazione delle variabili di volatilità	16
3.2.2	Creazione delle variabili temporali	16
3.2.3	Creazione delle variabili politiche	17
3.3	Configurazione modelli e setup dell'esperimento	17
3.3.1	Suddivisione Train, Validation e Test	17
3.3.2	Finestra temporale di Input	17
3.3.3	Normalizzazione dei dati	18

3.3.4	Ricerca degli iperparametri	18
3.3.5	Risorse computazionali	20
3.4	Considerazioni sulle metriche di valutazione	20
4	Risultati sperimentali e analisi	21
4.1	Configurazione finale ed iperparametri selezionati	21
4.1.1	Valutazione quantitativa delle prestazioni ed analisi dei risultati . .	22
4.1.2	Analisi dei risultati	23
4.2	Visualizzazione delle previsioni	23
4.3	Analisi dell'interpretabilità	25
4.3.1	Interpretabilità nel TFT	25
4.3.2	Interpretabilità nella LSTM	28
4.4	Differenze di interpretazione e discussione dei risultati	29
5	Conclusioni e sviluppi futuri	31
5.1	Conclusioni	31
5.2	Limitazioni dello studio e sviluppi futuri	32

1 Introduzione

1.1 Il contesto

Negli ultimi anni, la società ha assistito ad un aumento della polarizzazione politica ed economica, con un progressivo allontanamento dalle posizioni moderate, fenomeno che ormai coinvolge tutto il mondo. Questa tendenza si riflette non solo nel dibattito pubblico, ma anche nel comportamento economico e nelle percezioni individuali della realtà. L'idea di compromesso appare sempre più fragile, mentre la radicalizzazione delle posizioni diventa la norma, influenzando anche le decisioni finanziarie e di consumo.

Negli Stati Uniti, questa dinamica è particolarmente evidente a causa del sistema bipartitico, in cui l'alternanza tra Repubblicani e Democratici ha storicamente influenzato l'andamento dell'economia nazionale – e di conseguenza di quella globale. Le differenze nei modelli di governance adottati dai due partiti generano effetti distinti sulla crescita economica e sulle politiche fiscali (Hibbs, 1977). Hibbs evidenzia come i partiti perseguano obiettivi economici differenti, con effetti distinti su crescita, disoccupazione e inflazione.

Storicamente, i Democratici tendono a favorire la crescita e l'occupazione, mentre i Repubblicani si concentrano sulla stabilità monetaria, privilegiando una crescita più lenta ma sostenuta e un maggiore controllo dell'inflazione. Di conseguenza, gli attori economici adattano le loro aspettative in base al partito al governo: le imprese si aspettano politiche espansive sotto i Democratici, con aumenti negli investimenti e nei consumi, mentre i governi Repubblicani adottano politiche restrittive, riducendo la spesa pubblica e comprimendo la domanda interna (Reed, 2006).

Tuttavia, la polarizzazione negli Stati Uniti non si limita alle scelte economiche, ma si estende anche al livello affettivo e identitario. Come sottolineano West and Iyengar (2022), la *partigianeria politica* negli USA non è più soltanto una questione ideologica, ma è diventata una forte identità sociale. Questo ha portato a una crescente polarizzazione affettiva, ovvero un'ostilità sempre più marcata tra elettori di partiti opposti, indipendentemente dalle loro posizioni sulle singole questioni politiche. Di conseguenza, le differenze economiche tra

Repubblicani e Democratici non solo influenzano la macroeconomia, ma si riflettono anche nei comportamenti individuali: gli elettori del partito vincente tendono ad avere aspettative economiche ottimistiche e aumentano i loro consumi, mentre quelli del partito sconfitto vedono il futuro in modo più negativo, riducendo la propria propensione alla spesa (Gerber and Huber, 2009). Questo meccanismo rafforza ulteriormente le divisioni socio-economiche, creando cicli di fiducia e sfiducia nell'economia legati all'identità politica.

In un contesto segnato da volatilità ed incertezza, la previsione delle serie temporali diviene uno strumento strategico fondamentale per anticipare e interpretare le dinamiche economiche e sociali, offrendo un supporto decisivo sia agli operatori pubblici che privati.

1.2 Analisi dello stato dell'arte e ricerca della letteratura

Il mondo della previsione della serie temporali oggi più che mai coinvolge differenti campi di applicazione e sviluppo, con la partecipazione di economisti, matematici ed informatici. Fildes (1985) sosteneva che nonostante un forte sviluppo dei modelli econometrici, questi presentassero ancora diverse criticità, come la difficoltà nella selezione delle variabili o la scarsa applicabilità pratica, rendendoli de facto limitati a specifici contesti accademici. L'approccio dominante in quel periodo era basato su modelli statistici lineari, tra cui *ARIMA* e le prime versioni dei modelli vettoriali autoregressivi (*VAR*). Tuttavia, l'assenza di strumenti automatizzati per la scelta delle variabili e la difficoltà nell'adattare i modelli a scenari reali con dati complessi rappresentavano un ostacolo significativo per la diffusione delle previsioni quantitative in ambito aziendale e industriale.

Con il progresso tecnologico e il crescente accesso ai dati, il panorama della previsione delle serie temporali ha subito un'importante trasformazione. De Gooijer and Hyndman (2006) forniscono un quadro aggiornato delle evoluzioni intervenute nei vent'anni successivi al lavoro di Fildes, evidenziando come il progresso tecnologico e metodologico abbia portato ad una maggiore enfasi sulla validazione empirica e sull'adozione di metodi computazionali avanzati. Se negli anni '80 la previsione era ancora vincolata a modelli econometrici tra-

dizionali, nei primi anni 2000 iniziano ad emergere approcci non lineari, come i modelli a soglia (*SETAR*, *STAR*) e le primissime applicazioni delle reti neurali artificiali (*ANNs*).

Nonostante questi progressi, De Gooijer e Hyndman sottolineano diverse sfide ancora aperte, tra cui la necessità di valutare adeguatamente l'accuratezza delle previsioni, la mancanza di interpretabilità dei metodi più complessi e la crescente complessità computazionale. Tali questioni hanno segnato l'avvio di una nuova fase nella previsione delle serie temporali, in cui la combinazione di modelli tradizionali e tecniche di intelligenza artificiale risulta sempre più strategica. Per decenni, modelli come *ARIMA*, *VAR* e *GARCH* hanno dominato le applicazioni in campo economico e finanziario; ciononostante, la forte dipendenza dalla stazionarietà e le difficoltà nel catturare sistemi sempre più complessi hanno spinto i ricercatori a esplorare metodi più flessibili. In tale contesto, il lavoro pionieristico di Zhang (2003) ha mostrato l'efficacia delle architetture ibride, in cui la componente tradizionale (ad esempio, *ARIMA*) viene integrata con reti neurali artificiali (*ANNs*), riuscendo così a cogliere sia pattern lineari che non lineari.

Di fronte a queste limitazioni il *machine learning* (o apprendimento automatico) ha iniziato a guadagnare popolarità, grazie anche all'aumento delle capacità computazionali e alla crescente disponibilità di dati. Ciò ha consentito l'adozione di modelli di *machine learning* supervisionato in grado di identificare e sfruttare *pattern* autonomamente, catturando relazioni anche particolarmente complesse. Tang et al. (2022) evidenziano come l'introduzione nella letteratura di modelli basati su Alberi Decisionali (*Random Forest*, *Gradient Boosting*), *Support Vector Machines (SVMs)* e *Artificial Neural Networks (ANNs)* ha radicalmente trasformato il mondo delle previsioni delle serie temporali, offrendo prestazioni superiori rispetto ai modelli statistici tradizionali.

Ad ogni modo, questi modelli erano ancora limitati nella gestione delle dipendenze sequenziali dei dati, aspetto fondamentale quando le osservazioni sono intrinsecamente collegate nel tempo. Come evidenziato da Benidis et al. (2022), il punto di svolta è stato determinato dall'introduzione ed utilizzo delle Reti Neurali Ricorrenti (*RNN*) ed in particolare delle *Long*

Short Term Memory (LSTM), capaci di "ricordare" dinamicamente le informazioni passate e modellare le interdipendenze temporali con maggiore efficacia.

Negli ultimi anni, le architetture *Transformer* (Vaswani et al., 2017), inizialmente concepite per compiti di elaborazione del linguaggio naturale (*NLP*), hanno mostrato prestazioni eccellenti anche nel *forecasting* delle serie temporali. Ciò è dovuto in gran parte al meccanismo di *Self-Attention*, che consente di elaborare sequenze in parallelo e di catturare relazioni globali tra i dati, superando i limiti delle reti ricorrenti classiche. Questa capacità di modellare dipendenze e interazioni a lungo termine (Wen et al., 2023), unita a un'architettura altamente flessibile e personalizzabile, colloca i *Transformer* tra le soluzioni più avanzate attualmente disponibili nel panorama della previsione delle serie temporali.

1.3 Determinazione dell'obiettivo di ricerca

L'obiettivo di questa tesi è prevedere l'andamento di alcuni indicatori macrofinanziari statunitensi (ad esempio, *GDP* e indice *S&P 500*) e valutare come l'alternanza politica (partito al potere) possa incidere sulle previsioni, costruendo un dataset ad hoc che copra il periodo dal 1985 a oggi. Per farlo, saranno effettuate diverse previsioni multivariate su differenti orizzonti temporali, sperimentando modelli scelti in base allo stato dell'arte attuale, con particolare attenzione all'interpretabilità (sia intrinseca, sia mediante tecniche di tipo *post-hoc*, come *LIME*). Il dataset sarà suddiviso in *train*, *validation* e *test*, al fine di valutare la robustezza dei risultati.

Infine, verrà discussa l'interpretazione dei meccanismi interni dei modelli e l'impatto effettivo delle variabili "politiche" sui principali indicatori macro, evidenziando quanto le differenze politiche influenzino, in pratica, la qualità e l'accuratezza delle previsioni.

1.4 Struttura della tesi

Nel Capitolo 1 viene introdotto il tema, con una panoramica sul contesto, lo stato dell'arte e gli obiettivi specifici della ricerca.

Il Capitolo 2 illustra i concetti teorici e le principali tecniche di previsione utilizzate.

Nel Capitolo 3 si descrive la metodologia sperimentale adottata, incluse la costruzione del *dataset* e la configurazione dei modelli.

Il Capitolo 4 presenta i risultati empirici, confronta le prestazioni dei modelli e discute gli aspetti di interpretabilità.

Infine, il Capitolo 5 conclude la tesi evidenziando i principali contributi emersi, i limiti dello studio e le possibili prospettive future.

2 Fondamenti teorici e domain knowledge

2.1 Descrizione dei modelli utilizzati

2.1.1 Temporal Fusion Transformer

Il *Temporal Fusion Transformer* (TFT) è un'architettura neurale avanzata progettata per la previsione delle serie temporali multi-orizzonte, sviluppata con l'obiettivo di coniugare elevate prestazioni ed interpretabilità (Lim et al., 2020).

La sua creazione nasce dalla necessità di affrontare un problema cruciale nel *forecasting*: molti processi di previsione si basano su una molteplicità di dati eterogenei, che includono informazioni statiche (covariate fisse nel tempo), variabili note nel futuro e altre caratteristiche esogene osservabili solo nel passato. Tradizionalmente, i modelli di *deep learning* sono considerati “*black box*”, poiché non forniscono indicazioni chiare su quali variabili e quali momenti storici incidano maggiormente sul risultato. Il TFT, invece, nasce con una struttura incentrata sull'interpretabilità, rendendolo particolarmente adatto a contesti, come quello economico-finanziario o politico, dove le decisioni devono essere motivate da evidenze solide e trasparenti.

Un tratto distintivo del TFT è la capacità di produrre previsioni multi-orizzonte, fornendo stime per un intero intervallo temporale futuro (ad esempio, un mese o un trimestre), invece di limitarsi a prevedere il valore del passo successivo. Questo consente di pianificare azioni più strategiche e di lungo respiro.

Il *Temporal Fusion Transformer* (TFT) integra due componenti fondamentali per migliorare le previsioni nelle serie temporali: il meccanismo di *Self-Attention Multi-Head* e la *Variable Selection Network*.

Il *Self-Attention Multi-Head* consente al modello di apprendere quali momenti passati siano più rilevanti per prevedere il futuro, assegnando pesi diversi alle informazioni in base all'orizzonte temporale.

Parallelamente, la *Variable Selection Network* non si limita a valutare quali fasi temporali considerare con maggiore attenzione, ma seleziona in modo dinamico anche le *feature* più rilevanti tra variabili statiche, note o sconosciute.




Figura 1: Architettura Temporal Fusion Transformer

2.1.2 Long Short Term Memory

Per valutare l'efficacia del TFT, si è scelto di confrontarlo con un modello *baseline* ampiamente consolidato nella predizione delle serie temporali: la *Long Short-Term Memory* (LSTM) (Hochreiter and Schmidhuber, 1997). Le reti LSTM sono state una rivoluzione nell'ambito delle Reti Neurali Ricorrenti (RNN), poiché hanno risolto in gran parte il problema del *vanishing gradient*, ossia la tendenza del gradiente dell'errore a ridursi in modo esponenziale nel retropropagarsi su sequenze temporali molto lunghe. Questo ha consentito di catturare le dipendenze di lungo periodo, elemento fondamentale per serie temporali con pattern estesi o stagionalità rilevanti.

La scelta dell'*LSTM* "come termine di confronto" nasce dunque dalla sua diffusione e affidabilità: in molti contesti economici, industriali e di ricerca, la LSTM è ormai un punto di riferimento grazie alla sua comprovata efficacia su dati sequenziali. Tuttavia, essa può essere meno trasparente nel mostrare perché alcune variabili abbiano più peso di altre, oppure quali segmenti temporali risultino decisivi per la previsione finale. Sebbene le tecniche post-hoc di interpretazione possano fornire indizi a posteriori, queste soluzioni non sono integrate

nativamente nella struttura dell'*LSTM*.

Di conseguenza, il TFT risulta particolarmente interessante da confrontare con l'*LSTM* non soltanto per verificarne le performance predittive, ma anche per valutarne il grado di spiegabilità e di trasparenza offerto nativamente.




Figura 2: Architettura Long Short Term Memory

2.2 Scelta delle features

2.2.1 Introduzione

In questo paragrafo vengono illustrati i criteri adottati per selezionare ed implementare le variabili impiegate nei modelli predittivi, con particolare attenzione al modo in cui il *Temporal Fusion Transformer* gestisce e sfrutta tali variabili per garantire una maggiore stabilità al modello.

Il *dataset* considerato copre con frequenza giornaliera un arco temporale di 40 anni, dal 1° gennaio 1985 al 1° gennaio 2025, periodo durante il quale si sono avvicendati otto presidenti degli Stati Uniti, permettendo quindi di incorporare dinamiche di lungo periodo e di testare la robustezza del modello attraverso cambiamenti politici e macroeconomici significativi.

2.2.2 Categorie di variabili e motivazioni teoriche

Per catturare le diverse dimensioni che influenzano il comportamento del mercato e dei principali indicatori economici, il *dataset* include variabili di diversa natura, raggruppate come segue:

- **Variabili di mercato (S&P 500):** includono il prezzo di chiusura Close (Target), il prezzo di apertura Open, il volume di scambio Volume e il tasso di volatilità giornaliero calcolato come differenza fra il prezzo di apertura e chiusura `daily_volatility_pct_sp500`.

Riflettono in tempo reale la dinamica degli scambi ed il *sentiment* degli investitori, fornendo un segnale immediato sulle condizioni di mercato.

- **Indicatori Macroeconomici:** comprendono il Prodotto Interno Lordo Reale GDPC1 (Target), il Tasso di Interesse sui Fondi Federali DFF, il Tasso di Disoccupazione UNRATE, la Liquidazione Secondaria WM2NS e l'Indice dei Prezzi al Consumo CORESTICKM159SFRBATL.

Rappresentano i fondamentali dell'economia ed influenzano i flussi di capitale, consentendo di catturare l'impatto delle politiche monetarie e fiscali.

- **Indicatori di Sentiment:** includono l'Indice di Fiducia dei Consumatori dell'Università del Michigan UMCSENT, nonché vari indici di incertezza politica ed economica, come l'Indice di Incertezza Politica Giornaliero `daily_policy_index`, l'Indice Composito di Incertezza `Three_Component_Index` e l'Indice di Incertezza Basato sulle Notizie `News_Based_Policy_Uncert_Index`.

Misurano la percezione dell'economia ed il livello di incertezza dei consumatori ed investitori, anticipando possibili reazioni emotive dei mercati.

- **Variabili Politiche:** includono variabili binarie che rappresentano il controllo del governo e il contesto politico, come la *dummy* del partito al governo `party_dummy`, la *dummy* per il periodo di transizione politica `transition_dummy`, la *dummy* per il controllo del Senato `senate_dummy` e la *dummy* per il controllo della Camera dei Rappresentanti `hr_dummy`. In ultima istanza, la variabile `days_until_election` indica il numero di giorni mancanti alla data di insediamento alla presidenza.

Esprimono le condizioni di *governance* ed i periodi di transizioni amministrative, influenzando aspettative e politiche economiche.

- **Variabili Temporal:** comprendono la data del record `date`, il giorno della settimana `day_of_week`, il giorno del mese `day_of_month` e il mese `month`.

Consentono di cogliere pattern stagionali o ricorrenze giornaliere e mensili, fornendo un contesto fondamentale per l'analisi delle serie storiche.

2.2.3 Distinzione tra Known e Unknown Variables

Nel contesto del Temporal Fusion Transformer, è cruciale distinguere fra variabili *known* (note a priori) e variabili *unknown* (da prevedere).

Known Variables: Rientrano in questa categoria tutti i dati il cui valore è noto prima del momento della previsione. Ne sono un esempio le variabili temporali e quelle politiche. In alcuni casi, anche indicatori macroeconomici possono essere considerati “*known*” se esistono stime ufficiali comunicate in anticipo dalle autorità (ad esempio, i tassi di interesse annunciati dalla *Federal Reserve*).

Unknown Variables: Rappresentano, invece, i dati che non sono disponibili ex ante e che il modello deve imparare a prevedere. Ne fanno parte le variabili di mercato e la maggior parte degli indicatori di sentiment, poiché tipicamente non si conosce il loro valore futuro. Molti indicatori macroeconomici, inoltre, vengono pubblicati con ritardo rispetto al periodo di riferimento, risultando anch'essi sconosciuti.

Questa suddivisione incide direttamente sulla costruzione e sul *training* del modello, poiché il TFT sfrutta le informazioni “*known*” nell'orizzonte temporale di riferimento per migliorare la stima delle variabili “*unknown*”. In tal modo, il modello può integrare dati certi (come calendari, eventi politici o stime già disponibili) con le variabili da prevedere, ottimizzando la capacità predittiva complessiva.

Nome	Tipo	Freq.	Fonte	Known/Unknown
Variabili di Mercato				
S&P 500 (Close)	Continua	Giornaliera	Yahoo Finance	Unknown
S&P 500 (Open)	Continua	Giornaliera	Yahoo Finance	Unknown
S&P 500 (Volume)	Continua	Giornaliera	Yahoo Finance	Unknown
S&P 500 (Daily_Volatility_Pct_SP500)	Continua	Giornaliera	Yahoo Finance	Unknown
Indicatori Macroeconomici				
GDP Reale (GDPC1)	Continua	Trimestrale	FRED	Unknown
Tasso Fondi Federali (DFF)	Continua	Giornaliera	FRED	Known
Tasso Disoccupazione (UNRATE)	Continua	Mensile	FRED	Unknown
Liquidazione Secondaria (WM2NS)	Continua	Settimanale	FRED	Unknown
Indice Prezzi Consumo (CORESTICKM159SFRBATL)	Continua	Mensile	FRED	Unknown
Indicatori di Sentiment				
Indice Fiducia Consumatori (UMCSENT)	Continua	Mensile	UMICH	Unknown
Indice Incertezza Politica (daily_policy_index)	Continua	Giornaliera	EPU Database	Unknown
Indice Composito Incertezza (Three_Component_Index)	Continua	Mensile	EPU Database	Unknown
Indice Incertezza Notizie (News_Based_Policy_Uncert_Index)	Continua	Mensile	EPU Database	Unknown
Variabili Politiche				
Dummy Partito (party_dummy)	Dummy	Trimestrale	Wikipedia	Known
Dummy Transizione Politica (transition_dummy)	Dummy	Trimestrale	Wikipedia	Known
Dummy Controllo Senato (senate_dummy)	Dummy	Trimestrale	Wikipedia	Known
Dummy Controllo Camera (hr_dummy)	Dummy	Trimestrale	Wikipedia	Known
Giorni alle Elezioni (days_until_election)	Continua	Giornaliera	Wikipedia	Known
Variabili Temporal				
Data (date)	Indice	Giornaliera	Calendario	Known
Giorno della Settimana (day_of_week)	Categorica	Giornaliera	Calendario	Known
Giorno del Mese (day_of_month)	Categorica	Giornaliera	Calendario	Known
Mese (month)	Categorica	Giornaliera	Calendario	Known

Tabella 1: Composizione Dataset ed Implementazione nel TFT

3 Metodologia sperimentale

3.1 Preprocessing e pulizia dei dati

In questa sezione si descrive il flusso di lavoro adottato per la pulizia e la preparazione dei dati, al fine di garantire la coerenza temporale e la continuità delle serie prese in esame.

3.1.1 Caricamento e reindicizzazione del dataset

I dati relativi all'indice S&P 500 sono stati scaricati a partire dal 1° gennaio 1985 tramite la libreria `yfinance` (Aroussi, 2019). Un procedimento analogo è stato applicato per:

- Le variabili macroeconomiche, prelevate da Federal Reserve Economic Data (FRED) (2024),
- Gli indicatori di sentiment, forniti da Economic Policy Uncertainty Index (2024).

Al fine di ottenere una copertura temporale continua, si è creato un *range* uniforme di date giornaliere tra il primo e l'ultimo giorno effettivamente presente nei dati. Il *dataset* è quindi stato reindicizzato su questo *range*: ciò assicura che eventuali giornate di borsa chiusa o ritardi di rilascio per le variabili macro vengano esplicitati come assenze di dati (valori mancanti) e gestiti opportunamente.

3.1.2 Interpolazione dei valori mancanti

Dopo la reindicizzazione, i dati mancanti relativi all'S&P 500 (ad esempio, giornate in cui la borsa era chiusa o non si avevano rilevazioni complete) sono stati interpolati linearmente. Tale tecnica sfrutta i valori noti più vicini per stimare quelli mancanti, risultando adeguata per variabili finanziarie in cui si ipotizza un'evoluzione relativamente continua nel breve periodo.

3.1.3 Unificazione del fuso orario

Per evitare inconsistenze temporali dovute a fusi orari differenti tra le varie fonti, l'indice temporale è stato convertito e uniformato in un unico riferimento temporale. Tale passo previene discrepanze durante il processo di *join* e l'analisi successiva.

3.1.4 Merge con informazioni politiche e macroeconomiche

In seguito alla pulizia iniziale, il dataset finanziario è stato integrato con:

- Variabili Macroeconomiche ed Indicatori di Sentiment.
- Informazioni politiche, tra cui gli insediamenti presidenziali ed i partiti di maggioranza.

L'operazione è stata effettuata tramite un *outer join* per preservare il massimo delle informazioni. Per le variabili con frequenza non giornaliera (ad esempio, settimanale, mensile o trimestrale), è stata applicata una strategia di *forward fill* (riempimento in avanti), affinché i valori rimangano costanti fino al successivo aggiornamento ufficiale.

3.2 Feature Engineering

La fase di *feature engineering* mira ad arricchire il *dataset* con variabili derivate, utili a catturare *pattern* di mercato, dinamiche temporali e fattori politici.

3.2.1 Creazione delle variabili di volatilità

Volatilità percentuale giornaliera dell'S&P 500:

$$\text{daily_volatility_pct_sp500} = \left(\frac{\text{daily_volatility}}{\text{Open}} \right) \times 100$$

dove *daily_volatility* è stato calcolato come differenza giornaliera (assoluta) tra il prezzo di chiusura ed apertura dell'indice S&P 500. In tal modo si ottiene una misura percentuale della variabilità intragiornaliera.

3.2.2 Creazione delle variabili temporali

Per catturare *pattern* stagionali e ricorrenze rilevanti sul piano economico e finanziario, sono state generate:

- *day_of_week*: Giorno della settimana.

- `day_of_month`: Giorno del mese.
- `month`: Mese di riferimento.

3.2.3 Creazione delle variabili politiche

Per riflettere il contesto politico e il suo impatto sugli indicatori di mercato e macroeconomici, sono state incluse:

- **Dummies di Partito:** `party_dummy` (governo alla Casa Bianca), `senate_dummy` (maggioranza al Senato) e `hr_dummy` (maggioranza alla Camera dei Rappresentanti). Le variabili binarie valgono 0 in caso di Partito Repubblicano e 1 in caso di Partito Democratico.
- `transition_dummy`: assume valore 1 nel trimestre successivo a un insediamento presidenziale, per catturare possibili volatilità iniziali.
- `days_until_election`: conteggio dei giorni mancanti all'insediamento alla presidenza; funge da indicatore temporale di prossimità a potenziali cambiamenti politici.

3.3 Configurazione modelli e setup dell'esperimento

3.3.1 Suddivisione Train, Validation e Test

Per garantire un confronto equo tra i modelli e prevenire contaminazioni temporali:

- È stata adottata una suddivisione cronologica del *dataset* in *training* (70%), *validation* (15%) e *test* (15%).
- I primi 28 anni coprono il *training*, i successivi 6 la *validation* per ottimizzare gli iperparametri, mentre l'ultima finestra temporale funge da *test* finale per valutare le prestazioni.

3.3.2 Finestra temporale di Input

- **TFT:** viene utilizzata una finestra di *input* di 60 giorni e un orizzonte di previsione di 10 giorni (60-10) per prevedere il prezzo di chiusura di S&P 500. Tale scelta riflette la

volontà di catturare segnali a breve-medio termine e di ottenere proiezioni multi-step. Per GDPC1, invece, è stata adottata una finestra di *input* di 240 giorni ed un orizzonte di previsione di 90 giorni (240-90), in modo da rispettare la frequenza trimestrale dell'indicatore e fornire al modello un contesto storico più ampio, coerente con la sua dinamica macroeconomica.

- **LSTM:** prevede invece una sequenza di 120 giorni per la previsione S&P 500 come *input*, producendo previsioni a step successivi (multi-step). Invece, per la stessa ragione della scelta effettuata per il TFT, 240 giorni è stato scelto per GDPC1. L'idea è di fornire all'LSTM un maggior contesto storico, nella speranza di catturare dipendenze di più lungo periodo.

3.3.3 Normalizzazione dei dati

- **TFT:** per la previsione del prezzo di chiusura dell'S&P 500 è stato utilizzato l'EncoderNormalizer fornito dalla libreria `pytorch-forecasting`, che gestisce automaticamente la normalizzazione delle variabili, distinguendo tra covariate statiche, note e sconosciute, in linea con l'architettura del modello. Per il GDP (GDPC1), invece, si è rivelato più adatto il RobustScaler: basandosi sulla mediana e sull'intervallo interquartile (IQR) anziché sulla media e sulla deviazione standard, permette di preservare la stabilità della scala dei dati senza essere influenzato da variazioni estreme.
- **LSTM:** per la normalizzazione delle variabili di input è stato utilizzato lo StandardScaler, che trasforma i dati in una distribuzione con media zero e varianza unitaria. Questo approccio è particolarmente utile per stabilizzare l'addestramento delle reti ricorrenti, migliorando la convergenza e la qualità delle previsioni.

3.3.4 Ricerca degli iperparametri

Per entrambe le architetture, è stata eseguita un'ottimizzazione degli iperparametri, adottando strategie diverse per bilanciare accuratezza e velocità di ricerca:

- **TFT:** L'ottimizzazione è stata condotta con *Optuna*, un metodo di ricerca *Bayesiano* adattivo integrato in *pytorch-forecasting*, che esplora lo spazio degli iperparametri in modo intelligente, apprendendo dai risultati dei tentativi precedenti. Questa strategia è stata scelta per velocizzare il processo di *tuning* del TFT, che è un modello molto più complesso rispetto all'LSTM e richiede un'esplorazione più mirata degli iperparametri per evitare sprechi di risorse computazionali.

Optuna ha ottimizzato i seguenti iperparametri:

- Valore di *gradient clipping*.
- Dimensione dei *layer* nascosti (*hidden size*).
- Numero di teste di attenzione.
- *Learning rate*.
- Dropout rate.

È stata attivata la regolazione del *learning rate* con la strategia *reduce on plateau*, mentre il *batch size* è stato fissato a 128, basandosi su risultati sperimentali precedenti. È stato adottato un meccanismo di *Early Stopping*, con una pazienza di 30 epoche, per ridurre i tempi di addestramento e prevenire l'*overfitting*.

- **LSTM:** l'ottimizzazione è stata effettuata tramite *Keras Tuner* con *Random Search*, una metodologia che esplora lo spazio degli iperparametri in modo casuale, valutando ogni configurazione indipendentemente dalle precedenti. Sebbene meno efficiente rispetto a metodi più avanzati, il *Random Search* è stato scelto per la sua semplicità e per la relativa rapidità nel testare combinazioni di iperparametri in una rete ricorrente, dove il numero di parametri è inferiore rispetto all'architettura TFT.

La ricerca ha riguardato i seguenti iperparametri:

- Numero di neuroni per *layer*.
- *Batch size*.
- Numero di *layer*.

- *Dropout rate*.
- *Learning rate*.

Anche per la LSTM è stato implementato *Early Stopping* con una pazienza di 10 epoche, interrompendo l’addestramento qualora la metrica di validazione non mostrasse miglioramenti significativi.

3.3.5 Risorse computazionali

- **TFT**: addestrato su *GPU NVIDIA A100*, utile a gestire in maniera efficiente i calcoli paralleli tipici delle architetture *Transformer*.
- **LSTM**: addestrato su GPU NVIDIA L4, meno potente, ma comunque capace di sostenere il carico computazionale delle reti ricorrenti.

3.4 Considerazioni sulle metriche di valutazione

Nel presente lavoro, la scelta sulle metriche di valutazione dei risultati è ricaduta su:

- **RMSE** (*Root Mean Squared Error*): radice quadrata della media dei quadrati degli errori. Esprime l’errore medio nella stessa unità di misura della variabile e penalizza maggiormente gli errori di grande entità rispetto alla *MAE*.
- **MAE** (*Mean Absolute Error*): media degli errori in valore assoluto. Offre un’interpretazione più intuitiva, in quanto rappresenta l’errore medio in termini di unità di misura della variabile.
- **MAPE** (*Mean Absolute Percentage Error*): media degli errori percentuali in valore assoluto. Fornisce un’idea di quanto la stima si discosti in percentuale dal valore reale.
- **SMAPE** (*Symmetric Mean Absolute Percentage Error*): variante “simmetrica” del *MAPE*, riduce i problemi quando i valori reali sono molto prossimi a zero.

4 Risultati sperimentali e analisi

In questo capitolo vengono illustrati i risultati sperimentali ottenuti dai modelli *Long Short-Term Memory* (LSTM) e *Temporal Fusion Transformer* (TFT), addestrati secondo la strategia e la suddivisione temporale descritte nel Capitolo 3.

Dopo aver presentato la configurazione finale e gli iperparametri selezionati, si mostreranno le prestazioni quantitative (Sezione 4.1.1) e la visualizzazione delle previsioni (Sezione 4.2), per poi discutere l'interpretabilità (Sezione 4.3) e trarre le conclusioni finali (Sezione 4.4).

4.1 Configurazione finale ed iperparametri selezionati

Come anticipato, la ricerca degli iperparametri per i due modelli ha richiesto circa 200 iterazioni per ciascun target (Close dell'S&P 500 e GDPC1 per il PIL reale), seguendo procedure di *random search tuner* (tramite *Keras Tuner*) per la LSTM e *Bayesian search* (tramite *Optuna*) per il TFT.

In Tabella 2 e Tabella 3 si riportano le configurazioni finali risultate ottimali. Le scelte sui *batch size*, sul numero di neuroni, sul *dropout* e sugli ottimizzatori rispecchiano il compromesso migliore tra accuratezza e stabilità dell'addestramento, in linea con la finestra temporale di *input* specifica per ciascun target (Capitolo 3, Sezione 3.3.2).

4.1.1 Valutazione quantitativa delle prestazioni ed analisi dei risultati

Iperparametri	Close	GDPC1
LSTM Layers	1	2
Batch Size	128	128
Learning Rate	0.00093	0.01429
Hidden Size	8	16
Hidden Continuous Size	8	16
Attention Head Size	2	3
Dropout	0.4	0.2
Output Size	7	7
Optimizer	Ranger	Ranger
Gradient Clip Value	0.1	0.4849
Max Epochs	80	100
Numero di Parametri	13.9k	50.7k

Tabella 2: Configurazione degli iperparametri utilizzata per il modello TFT.

Iperparametri	Close	GDPC1
Numero di Neuroni	180	40
Batch Size	64	128
Numero di Layers	1	1
Dropout Rate	0.1	0.3
Learning Rate	0.01	0.01
Optimizer	AdamW	AdamW
Max Epochs	80	80
Numero di Parametri	147.1k	10.3k

Tabella 3: Configurazione degli iperparametri utilizzata per il modello LSTM.

Per il TFT, l'uso dell'ottimizzatore *Ranger* (basato su *RAdam* + *Lookahead*) si è rivelato decisivo per stabilizzare l'addestramento, specie nelle fasi iniziali, grazie alla sua capacità di regolare dinamicamente l'aggiornamento dei pesi. Come anticipato in Capitolo 3, l'EncoderNormalizer (per Close) e il RobustScaler (per GDPC1) hanno facilitato la gestione di valori estremi o outlier nei dati macroeconomici.

A seguito di questa configurazione, si sono ottenuti i risultati quantitativi riportati nelle tabelle seguenti, focalizzate sulle metriche presentate nel paragrafo 3.4 (*RMSE*, *MAE*, *MAPE*, *SMAPE*).

Modello	RMSE	MAE	MAPE (%)	SMAPE (%)
TFT	36.01	31.98	1.11	1.12
LSTM	467.79	338.93	7.18	7.59

Tabella 4: Confronto prestazioni per la previsione di Close

Modello	RMSE	MAE	MAPE (%)	SMAPE (%)
TFT	28.88	28.64	1.12	1.12
LSTM	711.97	581.11	6.03	6.09

Tabella 5: Confronto prestazioni per la previsione di GDPC1

4.1.2 Analisi dei risultati

Dall'analisi delle tabelle 4 e 5, emerge chiaramente la superiorità del modello TFT rispetto alla LSTM in entrambe le previsioni (Close e GDPC1), con errori significativamente più contenuti.

In particolare, per quanto riguarda *RMSE* e *MAE*, i valori ottenuti dal TFT risultano un ordine di grandezza più bassi per Close e persino più marcati per GDPC1. Per quanto riguarda *MAPE* e *SMAPE*, il TFT mantiene errori percentuali molto contenuti, mentre la LSTM tende maggiormente a soffrire i cambi di regime e la presenza di potenziali *outlier*, come indicato dalla maggiore sensibilità ai picchi.

Tuttavia, questa superiorità del TFT ha un costo: tempi di addestramento più lunghi e un maggior consumo di risorse computazionali, aspetti che riflettono la complessità intrinseca delle architetture transformer. Questo elemento non è trascurabile in un contesto applicativo industriale, dove l'equilibrio tra accuratezza e costi computazionali diventa un fattore critico di scelta (Capitolo 3, Sezione 3.3.5).

4.2 Visualizzazione delle previsioni

Per una comprensione più intuitiva del comportamento dei modelli, nella figure 3 e 4 si mostra l'andamento reale del target a fronte della previsione *multi-step* del TFT, su un segmento del

test set. Il grafico riporta sull'asse delle ordinate di sinistra i valori reali (linea continua in blu) e le previsioni *multi-step* sotto forma di quantili (area in arancione, con la linea arancione più scura che rappresenta il quantile mediano). Sull'asse di destra, invece, è mostrata l'evoluzione del peso di attenzione (linea grigia) che il modello assegna ai diversi passi temporali, grazie alla *self-attention multi-head* nativa del TFT.

È interessante osservare come il modello gestisca l'attenzione in presenza di due variabili che mostrano comportamenti profondamente differenti: nella predizione della variabile *Close* l'attenzione cresce lungo i passi temporali ed evidenzia picchi in corrispondenza di variazioni improvvise, adeguandosi alla volatilità tipica degli indicatori finanziari. Invece nella predizione di *GDPC1* l'attenzione risulta più stabile e tende a concentrare i propri picchi soltanto in prossimità di cambiamenti rilevanti, riflettendo la cadenza trimestrale e la maggiore lentezza con cui varia il PIL reale.




Figura 3: Previsione multi-step del TFT per *Close* con visualizzazione dell'attenzione.





Figura 4: Previsione multi-step del TFT per GDPC1 con visualizzazione dell'attenzione.

4.3 Analisi dell'interpretabilità


Un obiettivo cardine di questo studio è verificare come i due modelli gestiscano l'interpretabilità: da un lato, la LSTM con la necessità di metodi post-hoc, dall'altro, il TFT con meccanismi di *self-attention* e *variable selection* integrati.

4.3.1 Interpretabilità nel TFT

- **Self-Attention Multi-Head:** come mostrato in figura 3, 4, 5a e 5b, il modello fornisce, per ciascun passo storico, un coefficiente di attenzione che indica la rilevanza di quel punto nella determinazione della previsione.




(a) Attenzione per i passi temporali nella previsione di Close




(b) Attenzione per i passi temporali nella previsione di GDPC1

Figura 5: Confronto dell'attenzione sui passi temporali per Close (sinistra) e GDPC1 (destra).

- **Variable Selection Network:** All'interno del *Temporal Fusion Transformer*, la *Variable Selection Network* valuta l'importanza relativa di ciascuna *feature*, distinguendo tra variabili nell'*encoder* (sconosciute) e variabili nel *decoder* (conosciute):




(a) Decoder Importance - Close




(b) Decoder Importance - GDPC1

Figura 6: Importanza delle variabili (Decoder) per la previsione di Close (sinistra) e GDPC1 (destra).



(a) Encoder Importance - Close



(b) Encoder Importance - GDPC1

Figura 7: Importanza delle variabili (Encoder) per la previsione di Close (sinistra) e GDPC1 (destra).

• Decoder

- Figura 6 (sx): Mostra che, per la stima del Close dell'S&P 500, rivestono un peso rilevante le variabili politiche come *transition_dummy* e *party_dummy*, ancor più di quelle temporali. Ciò suggerisce che il TFT attribuisca particolare

importanza ai cambi di amministrazione e alle dinamiche politiche imminenti, interpretando tali informazioni come segnali di possibile volatilità o modifiche nelle aspettative degli attori economici.

- Figura 6 (dx): Anche in questo caso, `transition_dummy` si rivela la variabile più determinante, susseguita da `party_dummy` e la variabile macro DFF. Questo riflette la capacità del modello di integrare fattori istituzionali e politici per contestualizzare la direzione futura dell'economia.

- **Encoder**

- Figura 7 (sx): Nel caso di `Close`, il meccanismo di selezioni delle variabili nell'*encoder* attribuisce punteggi elevati in modo particolare ed inaspettato a `WM2NS`, susseguita da variabili di mercato e politiche come `Volume`, `party_dummy` e il target storico `Close`.
- Figura 7 (dx): Per `GDPC1`, l'encoder del modello assume un punteggio di oltre il 50% alla variabile politica `party_dummy`. Questo indica la presenza di ciclicità e comportamenti macroeconomici ricorrenti per i partiti politici alla casa bianca, come evidenziato dalla letteratura scientifica (Capitolo 1, Sezione 1.1).

I grafici evidenziano come le variabili politiche (`party_dummy`, `senate_dummy`, `hr_dummy`, `transition_dummy`, `days_until_election`) mostrino un'incidenza non trascurabile, sia in fase di encoder (per costruire il contesto storico) sia in fase di decoder (per generare la proiezione futura). Ciò conferma l'ipotesi che instabilità o continuità politica possano influenzare le attese dei mercati e l'andamento di variabili economiche, rendendole fattori centrali nella previsione.

La capacità del TFT di trattare separatamente covariate note e covariate sconosciute si traduce in una visione contestualizzata dei dati. Come mostrano i punteggi di importanza, il modello sfrutta in maniera efficace le informazioni politiche (note in anticipo) per calibrare la previsione di variabili più volatili (come `Close`) o più lente (`GDPC1`).

4.3.2 Interpretabilità nella LSTM

A differenza del TFT, la LSTM non dispone di meccanismi di interpretazione nativi. Per superare tale limitazione, si è adottata una metodologia post-hoc basata su LIME (*Local Interpretable Model-Agnostic Explanations*) (Ribeiro et al., 2016).

L'idea consiste nel “perturbare” localmente gli *input* di un punto di *test* e addestrare un modello interpretabile (in questo caso un piccolo regressore lineare) che approssimi la funzione decisionale della LSTM in quella zona. In questo modo, è possibile capire quali *feature* abbiano contribuito alla previsione finale, localmente intorno a quel particolare esempio.

Una volta ottenute le spiegazioni locali per un insieme di punti di *test*, sono stati aggregati i coefficienti di LIME per avere un'indicazione dell'importanza media delle feature su un sequenza di previsione, come mostrato nei grafici seguenti.




Figura 8: Importanza aggregata delle feature per la LSTM stimata mediante LIME su Close (sx) e GDPC1 (dx).

Figura 8 mostra l'importanza aggregata delle *feature* per la LSTM, stimata tramite *LIME*, per il target Close (a sinistra) e GDPC1 (a destra). In particolare, nella figura 8 (sinistra) emerge che la variabile target Close risulta predominante, seguita da Open e dall'indice di incertezza News_Based_Policy_Uncert_Index. Invece, nella figura 8 (destra) relativa a GDPC1, la stessa variabile predetta mostra un peso negativo molto marcato, mentre le *feature* day_of_month e Volume contribuiscono in misura decisamente minore.

Questi risultati evidenziano la minore capacità della LSTM di estrapolare informazioni rilevanti dalle *feature* diverse dal target storico. Va inoltre precisato che le informazioni

ottenute forniscono soltanto una visione approssimata dell'importanza delle variabili.

4.4 Differenze di interpretazione e discussione dei risultati

L'analisi comparativa tra TFT e LSTM ha evidenziato punti di forza e di debolezza sotto molteplici aspetti, in particolare per quanto riguarda l'interpretabilità e la *performance* quantitativa.

Da un lato, il TFT incorpora meccanismi di *self-attention* e *variable selection* in modo nativo, restituendo fin da subito indicazioni su quali *timesteps* e quali variabili abbiano un impatto maggiore sulla previsione.

Questa caratteristica permette di ottenere una visione globale dei fattori più rilevanti nel corso della finestra d'ingresso, evidenziando la persistenza di certi pattern o la rilevanza di variabili specifiche, come quelle di natura politica.

Dall'altro lato, la LSTM necessita di strumenti di interpretazione post-hoc che, per loro natura, forniscono spiegazioni localizzate solamente su piccoli esempi, complicando la comprensione complessiva del modello. Inoltre, le variabili politiche emergono solo parzialmente negli esiti di LIME, risultando più difficili da isolare rispetto alle dinamiche di mercato.

Sul piano quantitativo, il TFT ha evidenziato un errore complessivo nettamente inferiore (*RMSE*, *MAE*, *MAPE*, *SMAPE*) in entrambe le previsioni considerate (C10e e GDPC1), specialmente in scenari caratterizzati da elevata volatilità o transizioni politiche. Ciò suggerisce che l'architettura basata sull'attenzione e la gestione separata di covariate note e sconosciute consentano di catturare *pattern* temporalmente complessi e interazioni non banali tra fattori economici, politici e di mercato.

Un ulteriore vantaggio del TFT consiste nella giustificazione diretta delle previsioni: grazie alle mappe di attenzione e alle reti di selezione delle variabili, chi utilizza il modello può comprendere con immediatezza perché si registrano certe tendenze o variazioni. In settori sensibili come la finanza e la politica, questa “trasparenza” si rivela un valore aggiunto irrinunciabile. Invece, la LSTM si distingue per una minor complessità e tempi di addestramento

più brevi, il che può costituire un vantaggio in contesti applicativi con risorse computazionali limitate o in cui si preferisca un approccio consolidato ma meno esigente.

In conclusione, l'addestramento del TFT comporta innegabilmente maggiori costi in termini di tempo e risorse *GPU*, in gran parte dovuti all'elevato numero di parametri e profondità della rete, caratteristici delle architetture basate su *Transformer*. Di conseguenza, la decisione di quale modello adottare dipende spesso da vincoli pratici, come la disponibilità di infrastrutture *hardware*, i tempi d'addestramento tollerabili e il livello di approfondimento desiderato per l'interpretazione delle previsioni.

Sebbene la superiorità del TFT risulti evidente sul piano delle prestazioni e dell'interpretabilità, è fondamentale considerare con attenzione il *trade-off* tra accuratezza, costi computazionali e necessità di spiegabilità immediata. Mentre la LSTM garantisce una rapida implementazione e richiede meno risorse, il TFT offre una lettura dettagliata dei processi interni, grazie a meccanismi di attenzione e selezione delle variabili, a fronte di un maggiore impegno in fase di addestramento.

5 Conclusioni e sviluppi futuri

5.1 Conclusioni

In questo lavoro sono stati esplorati e confrontati due modelli di *time series forecasting*, mettendo in evidenza la crescente necessità di interpretabilità e l'importanza dell'*Explainable AI* (XAI), con particolare riferimento al potenziale impatto dell'alternanza politica statunitense sugli indicatori macrofinanziari. A tal fine, sono state create e integrate variabili politiche specifiche, così da valutare in che misura i cambi di amministrazione potessero influire sull'andamento dei mercati e sulle dinamiche economiche.

Per condurre l'analisi, si è scelto come architettura principale il *Temporal Fusion Transformer*, progettato appositamente per offrire meccanismi di interpretabilità nativa, affiancato da una LSTM (storicamente consolidata ed efficiente nella predizione sequenziale). Quest'ultima è stata resa interpretabile tramite la tecnica post-hoc *LIME*, consentendo un confronto diretto tra un modello intrinsecamente interpretabile e uno che richiede strumenti esterni di spiegazione.

Le sperimentazioni, condotte sul prezzo di chiusura dell'indice S&P 500 (Close) e sul PIL reale (GDPC1), hanno coperto un arco temporale di 40 anni, facendo emergere i seguenti punti chiave:

- **Prestazioni superiori del TFT:** grazie alla sua capacità di contestualizzare le informazioni (distinguendo fra covariate note e sconosciute) e di integrare variabili politiche, il TFT ha prodotto errori di previsione significativamente più bassi rispetto alla LSTM.
- **Interpretabilità integrata:** i meccanismi nativi del TFT, come *self-attention* e *variable selection* — hanno permesso di comprendere facilmente quali *timesteps* e quali *feature* abbiano influito maggiormente sulla previsione, offrendo una trasparenza essenziale in settori come la finanza o la politica economica.
- **Importanza delle variabili politiche:** le analisi hanno evidenziato come i dati relativi a transizioni amministrative e partiti al potere incidano in modo non trascurabile sia sul-

l'andamento dei mercati finanziari sia sulle traiettorie macroeconomiche, confermando il legame tra contesto politico e dinamiche economico-finanziarie.

5.2 Limitazioni dello studio e sviluppi futuri

Nonostante i risultati promettenti, il presente lavoro presenta alcuni vincoli che aprono la strada a possibili miglioramenti. In primo luogo, l'addestramento del TFT ha richiesto risorse computazionali elevate, che hanno imposto l'utilizzo di *GPU* a pagamento in ambiente *cloud*. Ciò sottolinea come, in contesti privi di infrastrutture adeguate, la complessità dell'architettura *transformer* possa costituire una barriera.

Un altro aspetto riguarda la mancanza di fonti di *sentiment* provenienti da *social media* o dall'analisi automatizzata delle dichiarazioni politiche. L'integrazione di flussi testuali e tecniche *NLP* avrebbe potuto fornire indicatori di *sentiment* più raffinati, cogliendo con maggiore prontezza eventuali oscillazioni del clima politico o economico. Questo passaggio, tuttavia, è influenzato da vincoli legati alla disponibilità e alla qualità dei dati, oltre che da problematiche di *privacy*.

Sul piano metodologico, nonostante il TFT si sia dimostrato particolarmente performante, esistono modelli basati sull'architettura *Transformer* più recenti che promettono di ridurre la complessità di calcolo. Un confronto sperimentale con tali soluzioni potrebbe aprire prospettive interessanti sia per l'accuratezza sia per la scalabilità.

Nel complesso, l'idea di combinare modelli di *forecasting* con informazioni politiche e analisi testuale si prospetta altamente promettente per tutti i settori in cui è cruciale disporre di previsioni accurate, affidabili e agevolmente interpretabili, in particolare in ambito economico, finanziario e istituzionale.

Riferimenti bibliografici

- Aroussi, R. (2019). yfinance: Yahoo! finance market data downloader. Accessed: 10-Feb-2025.
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., Maddix, D., Turkmen, C., Gasthaus, J., Bohlke-Schneider, M., Salinas, D., Stella, L., Aubet, F.-X., Callot, L., and Januschowski, T. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6):1–36.
- De Gooijer, J. G. and Hyndman, R. J. (2006). 25 years of time series forecasting. *International Journal of Forecasting*, 22(3):443–473. Twenty five years of forecasting.
- Economic Policy Uncertainty Index (2024). Measuring economic policy uncertainty. Accessed: Feb. 10, 2025.
- Federal Reserve Economic Data (FRED) (2024). Fred - federal reserve economic data. Accessed: Feb. 8, 2025.
- Fildes, R. (1985). Quantitative forecasting-the state of the art: Econometric models. *The Journal of the Operational Research Society*, 36(7):549–580.
- Gerber, A. S. and Huber, G. A. (2009). Partisanship and economic behavior: Do partisan differences in economic forecasts predict real economic behavior? *American Political Science Review*, 103(3):407–426.
- Hibbs, D. A. (1977). Political parties and macroeconomic policy. *The American Political Science Review*, 71(4):1467–1487.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Lim, B., Arik, S. O., Loeff, N., and Pfister, T. (2020). Temporal fusion transformers for interpretable multi-horizon time series forecasting.

- Reed, W. R. (2006). Democrats, republicans, and taxes: Evidence that political parties matter. *Journal of Public Economics*, 90(4):725–750.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). "why should i trust you?": Explaining the predictions of any classifier.
- Tang, Y., Song, Z., Zhu, Y., Yuan, H., Hou, M., Ji, J., Tang, C., and Li, J. (2022). A survey on machine learning models for financial time series forecasting. *Neurocomputing*, 512:363–380.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need.
- Wen, Q., Zhou, T., Zhang, C., Chen, W., Ma, Z., Yan, J., and Sun, L. (2023). Transformers in time series: A survey.
- West, E. A. and Iyengar, S. (2022). Partisanship as a social identity: Implications for polarization. *Political Behavior*, 44:807–838.
- Zhang, P. (2003). Zhang, g.p.: Time series forecasting using a hybrid arima and neural network model. *Neurocomputing*, 50:159–175.